

***Analisi e Predizioni di serie temporali in
Smart Building:
Valutazione delle tecniche di ML***

*Laurea Magistrale
in
“Ingegneria e scienze informatiche”*

Corso di Machine Learning

A.A. 2025/2026

Simone Rossato: VR527181

Indice

- 1. Motivazioni e Logica**
 - 1.1 Motivazione e contesto**
 - 1.2 Importanza del forecasting**
 - 1.3 Problema analizzato**
 - 1.4 Motivazione del confronto**
- 2. Stato dell'arte (SOTA)**
 - 2.1 Situazione attuale**
 - 2.2 Limiti e sfide**
- 3. Obiettivi**
 - 3.1 Obiettivo generale**
 - 3.2 Obiettivi specifici**
 - 3.2.1 Confronto tra modelli**
 - 3.2.2 Valutazione della Feature Selection**
- 4. Metodologia**
 - 4.1 Dataset**
 - 4.2 Data Pre-processing**
 - 4.3 Feature Selection**
 - 4.3.1 SelectKBest**
 - 4.3.2 Lasso-based**
 - 4.3.3 Random Forest-based**
 - 4.4 Modelli di Machine Learning**
 - 4.4.1 Linear Regression**
 - 4.4.2 Lasso Regression**
 - 4.4.3 Ridge Regression**
 - 4.4.4 Support Vector Regression**
 - 4.4.5 AdaBoost Regressor**
 - 4.4.6 Random Forest Regressor**
 - 4.5 Selezione degli hyper-parametri**
 - 4.5.1 Grid Search**

4.5.2 TimeSeriesSplit

4.6 Time Series Cross-Validation

5. Esperimento e risultati

5.1 Workflow dell'esperimento

5.2 Metriche di valutazione

5.2.1 Normalized Mean Absolute Error (NMAE)

5.2.2 Normalized Root Mean Square Error (NRMSE)

5.3 Risultati singola abitazione

5.4 Risultati vicinato

6. Conclusione

6.1 Sommario dell'esperimento

6.2 Limitazioni

6.3 Obiettivi futuri

Bibliografia

Capitolo 1

Motivazione e Logica

1.1 Motivazione e contesto

Negli ultimi anni il settore edilizio ha subito una profonda trasformazione dovuta alla diffusione di tecnologie digitali, sensori intelligenti e sistemi di monitoraggio. Ed è proprio in questo contesto che si inserisce il concetto di Smart Building, ovvero un edificio in cui gli impianti e le risorse energetiche vengono gestiti in maniera intelligente ed automatizzata, attraverso l'adozione di una infrastruttura di supervisione e controllo, al fine di minimizzare il consumo energetico e garantire il comfort, la sicurezza e la salute degli occupanti, assicurandone, inoltre, l'integrazione con il sistema elettrico di cui l'edificio fa parte.

Perciò, grazie a questi sensori e ai sistemi di monitoraggio, questi “edifici intelligenti” riescono a raccogliere continuamente dati relativi a diversi aspetti come quello ambientale o di consumo, rendendo possibile una gestione sempre più intelligente e sostenibile dell'edificio. È facile quindi intuire come tutto questo abbia favorito e reso importante le varie applicazioni di metodologie di Machine Learning, tra cui proprio il forecasting delle serie temporali.

1.2 Importanza del forecasting

Infatti il forecasting delle serie temporali sta avendo sempre più un ruolo centrale. La capacità di prevedere l'andamento futuro di variabili energetiche e ambientali consente di supportare sistemi di controllo predittivo e ottimizzare e migliorare l'efficienza complessiva dell'edificio. Tutte queste previsioni poi possono essere utilizzate per stimare consumi futuri, per pianificare il funzionamento degli impianti HVAC (Heating, Ventilation and Air Conditioning) e per monitorare gli indicatori legati alla sostenibilità ambientale. La stessa letteratura [\[1\]](#) scientifica mostra proprio come questo tema sia diventato uno dei principali campi di applicazione delle tecniche di Machine Learning.

1.3 Problema analizzato

Il presente progetto si concentra sull'analisi di due differenti scenari appartenenti al contesto delle Smart Buildings.

Il primo scenario riguarda l'analisi di una singola abitazione e ha come obiettivo la previsione della *Cooling Demand*: tale variabile rappresenta la quantità di energia richiesta per garantire un buon livello di temperatura degli ambienti interni. È stata scelta come variabile di studio poiché una sua previsione accurata potrebbe supportare la gestione degli impianti HVAC (Heating, Ventilation & Air Conditioning) e contribuire alla riduzione dei consumi energetici senza compromettere il comfort degli occupanti.

Il secondo scenario invece prende in considerazione un contesto più ampio. Infatti si andrà ad analizzare un vicinato, costituito da più abitazioni, e ha come obiettivo la previsione della *Carbon Intensity*: questa variabile rappresenta l'intensità delle emissioni associate al consumo energetico e costituisce un indicatore rilevante per valutare la sostenibilità ambientale di una comunità energetica. Il motivo della sua scelta è data proprio dal fatto che una sua previsione corretta può essere un supporto importante per la pianificazione energetica e per le politiche orientate alla sostenibilità.

1.4 Motivazione del confronto

L'analisi congiunta di questi due scenari ha l'obiettivo di valutare il comportamento delle tecniche di Machine Learning in contesti differenti, caratterizzati da target e dinamiche temporali diverse ma accomunati dall'appartenenza al settore degli Smart Buildings.

Inoltre numerosi modelli sono stati applicati a questo tipo di problemi, tuttavia non esiste una soluzione universalmente migliore. Per questo motivo il presente progetto propone un confronto tra sei differenti algoritmi di Machine Learning con l'obiettivo di analizzare il comportamento di modelli appartenenti a famiglie differenti, confrontandoli all'interno dello stesso framework sperimentale.

Capitolo 2

Stato dell'arte (SOTA)

2.1 Situazione attuale

Come introdotto nel capitolo precedente, le Smart Buildings generano grandi quantità di dati provenienti da sensori, sistemi HVAC, smart meters e dispositivi IoT. Questa sempre più crescente disponibilità di dati ha favorito l'adozione di tecniche di Machine Learning per applicazioni quali la previsione dei consumi energetici, il controllo intelligente degli impianti, la rilevazione di anomalie e la gestione della domanda energetica.

Diversi studi^[4] scientifici hanno evidenziato come il forecasting rappresenti una delle applicazioni più rilevanti del Machine Learning nel settore degli Smart Buildings e, nello specifico, la letteratura^[2] distingue generalmente tra approcci statistici tradizionali e approcci basati sul Machine Learning.

I primi includono modelli come ARIMA e SARIMA, mentre i secondi comprendono tecniche di regressione lineare, Support Vector Machines, algoritmi ensemble e, più recentemente, modelli di Deep Learning. Questi studi^[3] mostrano inoltre che i modelli di Machine Learning risultano spesso più efficaci quando devono gestire relazioni non lineari e dataset multivariati.

Tra i modelli maggiormente utilizzati figurano la Linear Regression e le sue varianti regolarizzate, come Ridge e Lasso, apprezzate per la loro semplicità interpretativa e il basso costo computazionale. Parallelamente, tecniche più sofisticate come Support Vector Regression (SVR), Random Forest e algoritmi di boosting hanno mostrato ottime prestazioni in numerosi problemi di previsione energetica grazie alla loro capacità di modellare relazioni non lineari tra le variabili.

Un ulteriore aspetto affrontato riguarda la selezione delle feature. I dataset impiegati nelle Smart Buildings possono contenere un numero elevato di variabili e, per ridurre la dimensionalità del problema e migliorare le prestazioni dei modelli, vengono spesso adottate tecniche di Feature Selection appartenenti alle categorie filter, wrapper ed embedded

2.2 Limiti e sfide

Nonostante i significativi progressi, il forecasting presenta ancora numerose sfide.

Una delle principali criticità riguarda l'assenza di un modello universalmente migliore per tutti gli scenari applicativi. Infatti le prestazioni degli algoritmi utilizzati dipendono fortemente da molti aspetti, per esempio alle caratteristiche del dataset, dal tipo di variabile che si vuole analizzare e predire. Di conseguenza, modelli ottimali per un determinato scenario possono produrre prestazioni e risultati inferiori in altri contesti.

Un secondo possibile problema è legato alle feature, sia dal punto di vista qualitativo che quantitativo. Infatti nella realtà i dataset contengono frequentemente informazioni ridondanti, irrilevanti o contengono semplicemente rumore e tutto ciò può ridurre la capacità di generalizzazione dei modelli. Anche se precedentemente abbiamo parlato della Feature Selection e su come possa rappresentare una possibile soluzione a questo tipo di problema, il suo impatto varia rispetto all'algoritmo utilizzato e perfino al problema che si vuole analizzare.

Infine un'ultima criticità riguarda la validazione dei modelli. Molti studi utilizzano ancora strategie di train-test split o cross-validation tradizionale che non mantengono la struttura temporale dei dati. Ciò porta a fenomeni di data leakage e a produrre stime ottimistiche ma false o errate.

Alla luce quindi di queste considerazioni, risulta evidente la necessità di confrontare diversi modelli e diverse strategie di Feature Selection all'interno di un framework sperimentale coerente, adattando procedure di validazione che tengano in considerazione la struttura temporale.

Capitolo 3

Obiettivi

3.1 Obiettivo generale

Il presente progetto, quindi, si inserisce nell'ambito della valutazione comparativa delle tecniche di Machine Learning per il forecasting in Smart Buildings, analizzando sia l'effetto della scelta dell'algoritmo sia l'influenza di differenti strategie di Feature Selection in due scenari applicativi distinti: la previsione della *Cooling Demand* a livello di singola abitazione e la previsione della *Carbon Intensity* a livello di vicinato.

L'obiettivo generale consiste nel valutare le prestazioni di diverse tecniche di Machine Learning applicate al forecasting di serie temporali in ambito Smart Building. In particolare, attraverso un framework sperimentale comune, il progetto mira a confrontare modelli appartenenti a differenti famiglie di algoritmi e ad analizzare l'influenza delle tecniche di Feature Selection sulle capacità predittive dei modelli.

L'analisi ha lo scopo di individuare le configurazioni maggiormente efficaci in entrambi gli scenari e comprendere come la scelta del modello e delle feature influenzi le prestazioni ottenute

3.2 Obiettivi specifici

Per raggiungere l'obiettivo generale, il progetto è stato articolato in due obiettivi specifici. Infatti come abbiamo sempre riportato, l'obiettivo principale è quello di confrontare i vari modelli in modo da scovare in questo contesto un possibile vincitore e per ognuno di questi modelli verranno confrontate varie configurazioni, ovvero il modello senza feature selection e il modello con tre differenti tecniche: SelectKBest, Lasso e Random Forest.

Tale impostazione ci permette di valutare sia l'efficacia dei modelli sia il possibile contributo da parte delle diverse strategie di Feature Selection

3.2.1 Confronto tra modelli

Il primo obiettivo, come detto, consiste nel confrontare le prestazioni di differenti algoritmi di Machine Learning applicati ai due problemi di forecasting considerati.

Per ciascun algoritmo viene effettuata una fase di ottimizzazione degli iperparametri mediante Grid Search combinata con TimeSeriesSplit, seguita da una valutazione tramite Time Series Cross Validation.

Le prestazioni verranno infine misurate attraverso le metriche NMAE e NRMSE al fine di identificare il modello più efficace per ciascun scenario applicativo.

L'obiettivo finale perciò è determinare quali algoritmi risultino maggiormente adatti, verificando inoltre se il comportamento dei modelli rimanga coerente nei due contesti analizzati.

3.2.2 Valutazione della Feature Selection

Il secondo obiettivo specifico riguarda l'analisi dell'impatto delle tecniche di Feature Selection sulle prestazioni dei modelli di Machine Learning.

Per ciascun algoritmo vengono considerate quattro differenti configurazioni: utilizzo del dataset completo senza feature selection; utilizzo della tecnica SelectKBest; utilizzo della Lasso-based feature selection; utilizzo della Random Forest-based feature selection.

Lo scopo è valutare se la riduzione del numero di feature contribuisca o meno a migliorare l'accuratezza predittiva dei modelli e individuare quale strategia di selezione risulti maggiormente efficace nei diversi scenari.

Per ogni algoritmo viene pertanto identificata la configurazione che produce i migliori risultati. Successivamente, le configurazioni migliori

vengono confrontate tra loro al fine di individuare la combinazione più performante.

Capitolo 4

Metodologia

4.1 Dataset

In questo capitolo vengono descritte le metodologie e gli strumenti utilizzati per lo sviluppo del progetto. La procedura adottata comprende diverse fasi, dove la prima riguarda l'analisi del dataset utilizzato.

Il dataset utilizzato proviene dalla CityLearn Challenge^[5], una competizione internazionale organizzata nell'ambito della conferenza NeurIPS e ospitata sulla piattaforma Alcrowd. In particolare è stato utilizzato il dataset relativo al Forecasting Track, il quale rappresenta un vicinato sintetico composto da abitazioni unifamiliari, a cui si aggiungono informazioni aggiuntive di contorno come il costo dell'elettricità, il volume di emissioni e il tempo meteorologico.

Nello specifico il dataset è composto dai seguenti file in formato csv, i quali contengono un totale di 720 rilevazioni effettuate a intervalli regolari di un'ora:

- weather.csv: dati meteorologici effettivi relativi alla posizione degli edifici utilizzati per fornire valori di osservazione all'ambiente
- carbon_intensity.csv: tasso effettivo di emissione proveniente dal mix di rete (kgCO₂e/kWh).
- pricing.csv: tariffa elettrica a tempo di utilizzo (TOU) (\$/kWh).
- building_1...n.csv: i dati delle serie temporali di ciascun edificio includono variabili temporali (calendario), domanda di utilizzo finale, generazione solare e variabili dell'ambiente interno.

4.2 Data Pre-processing

Dopo aver descritto il dataset, è necessario analizzare una fase molto importante, ovvero la fase di data pre-processing, la quale ha il compito di preparare i nostri dati per le successive attività di forecasting. Riveste un ruolo importante poiché la qualità dei nostri dati influenza direttamente le prestazioni dei modelli che si andranno ad utilizzare.

La prima operazione consiste nel caricamento e nell'integrazione dei dati tramite la libreria python pandas, al fine di ottenere un unico dataframe contenente tutte le informazioni necessarie. In particolare, nel caso del vicinato, andremo a caricare più di una building e andremo a togliere le informazioni ridondanti e a rinominare invece certe variabili in modo da evitare conflitti dopo la fusione.

Successivamente sono state generate diverse variabili lag per il target che si vuole predire *Cooling Demand* e *Carbon Intensity*, rispettivamente per la singola abitazione e il vicinato, in modo tale da fornire ai nostri modelli una conoscenza maggiore sul passato. La loro creazione introduce valori mancanti nelle prime osservazioni, tali valori sono stati rimossi per garantire la correttezza del processo di training.

Infine è stata applicata la classica pipeline utilizzata nei metodi di supervised learning, ovvero separare le feature dai target ed eseguendo, ove necessario, operazioni di normalizzazione o standardizzazione.

4.3 Feature Selection

Tra le operazioni preliminari considerate assume particolare importanza la fase di Feature Selection, ovvero il processo di selezione delle variabili di input per il modello utilizzando solo dati rilevanti ed eliminando il possibile rumore.

Oltre a ridurre la dimensionalità, può contribuire a migliorare l'interpretabilità, andando così a limitare il rischio di overfitting e a diminuire i tempi di training.

Poiché uno degli obiettivi consiste nel valutare l'impatto di questa tecnica, questa fase è stata analizzata separatamente rispetto alle altre operazioni di data pre-processing. In particolare sono state considerate tre differenti tecniche: SelectKBest, Lasso e Random forest.

Ciascuna metodologia nello specifico è stata applicata indipendentemente al dataset e successivamente confrontata in modo da mostrare quale tecnica fornisca le prestazioni migliori.

4.3.1 Select K-Best

La tecnica Select K-Best seleziona un sottoinsieme di K variabili che presentano la maggiore significatività statistica rispetto alla variabile target. L'algoritmo valuta quindi l'impatto di ciascuna feature in modo indipendente applicando test statistici specifici e ordinando le variabili in base al punteggio ottenuto.

La sua scelta deriva dalla sua efficienza computazionale. Infatti consente di effettuare un filtraggio preliminare su dataset di grandi dimensioni, eliminando le variabili che non mostrano alcuna correlazione con il target

4.3.2 Lasso-based

La tecnica Lasso introduce una penalizzazione/regolarizzazione di tipo L1 all'interno della funzione di costo di una linear regression. La particolarità di questa regolarizzazione risiede nella capacità di ridurre a zero i coefficienti associati alle variabili predittive meno rilevanti o ridondanti.

Utilizzata perché unisce le fasi di training e di selezione in un unico processo e permette di ottenere modelli altamente interpretabili, risolvendo intrinsecamente i problemi di multicollinearità tra le variabili

4.3.3 Random Forest-based

Quest'ultima tecnica appartiene ai metodi di Ensemble Learning. L'importanza di ciascuna feature viene quantificata calcolando la riduzione media dell'impurità prodotta da ciascuna variabile durante la costruzione

degli alberi. Le feature che contribuiscono maggiormente alla riduzione dell'errore vengono considerate più rilevanti e selezionate per le fasi successive di training.

Rispetto alle tecniche precedenti, la Random Forest è in grado di intercettare relazioni non lineari e interazioni complesse tra le feature.

4.4 Modelli di Machine Learning

Per il nostro progetto sono stati selezionati sei algoritmi di Machine Learning appartenenti a differenti famiglie di modelli. La scelta è stata effettuata con l'obiettivo di confrontare approcci caratterizzati da differenti livelli di complessità e capacità di modellare relazioni lineari e non.

Nello specifico sono stati considerati modelli lineari, modelli regolarizzati, algoritmi basati su Support Vector Machine e tecniche di ensemble learning.

4.4.1 Linear Regression

Uno dei più semplici e diffusi algoritmi di regressione. Mira a modellare la relazione tra una variabile dipendente e una o più variabili indipendenti, stimando i coefficienti che minimizzano l'errore di previsione.

Grazie alla sua semplicità viene solitamente utilizzata come modello di riferimento per valutare le prestazioni degli altri algoritmi.

4.4.2 Lasso Regression

Variante della Linear Regression che introduce una regolarizzazione di tipo L1, ovvero la regolarizzazione nella funzione di costo utilizza i valori assoluti dei coefficienti. Tale penalizzazione riduce la complessità del modello e tende ad annullare (porre a zero) i coefficienti associati a feature meno rilevanti, eseguendo praticamente una feature selection.

Questa variante previene l'overfitting e migliora l'interpretabilità e la generalizzazione del modello.

4.4.3 Ridge Regression

Altra variante della Linear Regression che, a differenza della Lasso, introduce una regolarizzazione di tipo L2, ovvero utilizza il quadrato dei coefficienti anziché il valore assoluto.

Un'altra differenza rispetto alla Lasso è che i coefficienti non vengono eliminati ma ridotti in ampiezza, rendendo il modello meno sensibile al problema della collinearità.

4.4.4 Support Vector Regression

È l'estensione della Support Vector Machine ai problemi di regressione. L'algoritmo ricerca una funzione che contemporaneamente approssimi i dati mantenendo l'errore entro una soglia prefissata e massimizzi la capacità di regolarizzazione. Sfruttando la selezione del kernel, è in grado di modellare anche relazioni non lineari.

4.4.5 AdaBoost Regressor

Metodo ensemble basato sul principio del boosting. Il modello combina diversi weak regressor, i quali vengono appresi in modo sequenziale, assegnando maggiore attenzione/peso alle osservazioni che commettono la maggior quantità di errori.

L'obiettivo è migliorare progressivamente le prestazioni complessive del modello.

4.4.6 Random Forest Regressor

L'ultimo modello è anch'esso un algoritmo ensemble basato però sul principio del bagging e che sfrutta la costruzione di molteplici decision tree. Ogni albero viene addestrato su diversi campionamenti del nostro dataset, in modo tale che ogni modello fornisca una previsione differente. La previsione finale verrà calcolata aggregando le predizioni dei singoli alberi. Tutto ciò permette di ridurre la varianza del modello e di catturare efficacemente relazioni non lineari.

4.5 Selezione degli hyper-parametri

Le prestazioni dei modelli però non dipendono esclusivamente dai dati utilizzati per il training, i quali come discusso subiscono una fase di pre-processing, ma anche dalla corretta selezione degli hyper-parametri. A differenza dei parametri appresi durante il training, gli hyper-parametri devono essere definiti prima di eseguire il training e influenzano direttamente il comportamento dei nostri modelli.

La scelta dei valori da attribuire agli hyper-parametri è fondamentale, perché altrimenti possono portare a fenomeni di underfitting o overfitting, compromettendo la qualità delle previsioni. Per questo motivo, è stata eseguita una fase di ottimizzazione per ottenere i migliori valori per ciascun modello considerato.

4.5.1 Grid Search

La ricerca della configurazione ottimale è stata effettuata mediante l'utilizzo della tecnica di Grid Search, la quale è una tecnica di ottimizzazione basata sulla ricerca esaustiva di tutte le possibili combinazioni di valori appartenenti a un insieme predefinito di hyper-parametri. Per ciascuna configurazione, il modello viene addestrato e valutato secondo una specifica procedura di validazione.

Al termine della ricerca, viene selezionata la configurazione che offre le migliori prestazioni.

Nonostante possa risultare computazionalmente costosa, essa rappresenta una delle tecniche più utilizzate grazie alla sua semplicità e alla capacità di fornire configurazioni efficaci per ciascun modello.

4.5.2 TimeSeriesSplit

Poiché il problema affrontato riguarda serie temporali, la procedura di ottimizzazione deve adottare un meccanismo che mantenga intatto l'ordine cronologico dei dati. Per questo motivo la ricerca è stata effettuata tramite Grid Search, come definito precedentemente, ma in combinazione con TimeSeriesSplit, consentendo così di individuare i migliori hyperparametri senza introdurre informazioni provenienti dal futuro.

Questa metodologia suddivide il dataset in partizioni temporali consecutive e, a ogni iterazione, utilizza le osservazioni passate per il training e quelle successive per la validazione. In questo modo è possibile selezionare gli hyper-parametri migliori rispettando la struttura temporale dei dati.

4.6 Time Series Cross-Validation

Dopo aver individuato la configurazione ottimale degli hyper-parametri, è necessario valutare le prestazioni dei modelli su dati non utilizzati durante la fase di training.

Nel contesto delle serie temporali, come accennato poco fa, tale valutazione deve preservare la dipendenza temporale tra le osservazioni. Per questo motivo è stata adottata una procedura di Time Series Cross-Validation. A differenza delle tradizionali strategie di cross-validation, la tecnica presa in esame addestra il modello utilizzando esclusivamente osservazioni passate e genera previsioni su osservazioni future. Al termine di ogni iterazione, la finestra di training viene aggiornata andando ad includere i nuovi dati disponibili e il processo viene ripetuto fino al termine della serie temporale presa in esame.

Questo approccio permette di simulare il processo di previsione che si verificherebbe in un contesto reale, garantendo che nessuna informazione futura venga utilizzata durante la fase di training. Inoltre, permette di ottenere una stima più affidabile delle capacità di generalizzazione e di confrontare correttamente le prestazioni delle diverse configurazioni.

Capitolo 5

Esperimento e risultati

5.1 Workflow dell'esperimento

In questo capitolo vengono descritti gli esperimenti condotti e i risultati ottenuti mediante l'applicazione dei modelli presentati nel capitolo precedente. L'obiettivo è di valutare le loro prestazioni in due scenari distinti: la previsione della *Cooling Demand* e della *Carbon Intensity* rispettivamente a livello di singola abitazione e di vicinato.

Tutti gli esperimenti sono stati condotti seguendo una procedura comune. In una prima fase, i diversi file che compongono il dataset CityLearn sono stati integrati in un unico dataset. Successivamente, sono state generate ulteriori feature temporali mediante la creazione di variabili lag della variabile target, al fine di fornire ai modelli una conoscenza aggiuntiva sull'andamento storico della serie temporale.

Una volta completata la fase di pre-processing, è stata eseguita l'ottimizzazione degli hyper-parametri mediante GridSearch combinata con TimeSeriesSplit, consentendo così di individuare la configurazione ottimale per ciascun algoritmo rispettando l'ordine temporale.

Nello specifico per ogni modello sono stati utilizzati i seguenti valori derivati dall'analisi di esempi o dall'utilizzo di euristiche:

- Linear Regression: nessun parametro
- Lasso Regression:
 - $\alpha = [0.0001, 0.001, 0.01, 0.1, 1]$
- Ridge Regression:
 - $\alpha = [0.01, 0.1, 1, 10, 100]$
- Support Vector Regression:
 - $C = [0.1, 1, 10]$
 - $\epsilon = [0.01, 0.1, 1]$

- gamma = [scale, auto]
- AdaBoost:
 - n_estimators = [50, 100, 200]
 - learning_rate = [0.01, 0.1, 1]
- Random Forest:
 - n_estimators = [50, 100]
 - max_depth = [None, 10, 20]
 - min_samples_split = [2, 5]
 - min_samples_leaf = [1, 2]

Una volta individuata la configurazione ottimale degli hyper-parametri, ciascun modello è stato valutato in quattro differenti configurazioni: utilizzo dell'intero insieme di feature e applicazione della feature selection tramite SelectKBest, tramite Lasso e infine tramite Random Forest.

Dopo aver eseguito la selezione delle feature, per quelle configurazioni di modelli che lo richiedevano, è stata eseguita una normalizzazione o standardizzazione.

Le prestazioni finali sono state valutate attraverso la procedura di Time Series Cross-Validation, descritta nel capitolo precedente. Per ciascuna iterazione della procedura sono state generate le previsioni e successivamente calcolate due metriche: NMAE e NRMSE.

I risultati riportati nelle sezioni successive, corrispondono alla media delle metriche ottenute nelle diverse iterazioni della procedura di validazione

Infine, per ogni modello sono state confrontate tra loro le configurazioni al fine di individuare la migliore e capire se in questo particolare dataset l'utilizzo della Feature Selection possa portare a prestazioni migliori. Dopodiché le migliori configurazioni di ogni modello sono state successivamente confrontate per identificare invece il modello più efficace e performante nei due scenari analizzati.

5.2 Metriche di valutazione

Per valutare le prestazioni dei modelli sono state utilizzate due metriche di errore: la Normalized Mean Absolute Error (NMAE) e la Normalized Root Mean Square Error (NRMSE).

Entrambe ci consentono di misurare la differenza tra i valori reali e quelli predetti, fornendo quindi una stima della qualità delle previsioni svolte dal modello. Nello specifico valori più bassi di NMAE e NRMSE indicano una maggiore precisione delle previsioni e quindi prestazioni migliori.

Infine, è stata utilizzata la loro versione normalizzata (Normalized) per rendere i risultati indipendenti dalla scala della variabile target e consentire confronti più significativi tra modelli e scenari differenti.

5.2.1 Normalized Mean Absolute Error (NMAE)

La NMAE misura l'errore assoluto medio commesso dal modello rispetto ai valori osservati. La versione normalizzata consente di facilitare il confronto tra differenti modelli.

Formalmente, è definita dalla seguente formula:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \qquad \text{NMAE} = \frac{\text{MAE}}{\text{Normalization Factor}}$$

dove:

- y_i rappresenta il valore reale
- $\hat{y}$ rappresenta il valore predetto;
- n è il numero di osservazioni;
- Normalization Factor è il fattore di normalizzazione dato dalla differenza tra il max e il min dei valori reali

Questa metrica attribuisce lo stesso peso a tutti gli errori e risulta particolarmente intuitiva da interpretare, poiché esprime la deviazione media delle previsioni rispetto ai valori osservati

5.2.2 Normalized Root Mean Square Error (NRMSE)

La NRMSE misura la radice quadrata dell'errore quadratico medio normalizzata rispetto all'intervallo dei valori osservati.

Formalmente è definita dalla seguente formula:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \qquad \text{NRMSE} = \frac{\text{RMSE}}{\text{Normalization Factor}}$$

dove:

- y_i rappresenta il valore reale
- $\hat{y}$ rappresenta il valore predetto;
- n è il numero di osservazioni;
- Normalization Factor è il fattore di normalizzazione dato dalla differenza tra il max e il min dei valori reali

A differenza della NMAE, la NRMSE penalizza maggiormente gli errori di grandi dimensioni a causa dell'elevamento al quadrato. Proprio per questo motivo fornisce informazioni aggiuntive sulla capacità del modello di gestire previsioni particolarmente difficili o che presentano errori elevati.

L'utilizzo congiunto di NMAE e NRMSE consente di ottenere una valutazione ancora più completa riguardo le prestazioni, considerando sia l'errore medio complessivo sia l'impatto delle previsioni caratterizzate da errori particolarmente elevati.

5.3 Risultati Singola abitazione

La presente sezione riporta i risultati ottenuti nel primo scenario analizzato relativo alla previsione della *Cooling Demand* di una singola abitazione.

Il dataset utilizzato è costituito dai dati della singola abitazione (Building_1) integrati con le variabili ambientali di contorno (carbon_intensity, pricing, weather). Prima della fase di training è stata

effettuata un'analisi preliminare utilizzando la matrice di correlazione, al fine di individuare possibili relazioni tra le variabili disponibili e la variabile target.

Dall'analisi della matrice di correlazione (Figura 1) emerge la presenza di correlazioni significative tra la *Cooling Demand* e diverse variabili meteorologiche. Inoltre, numerose feature mostrano elevati livelli di correlazione reciproca, evidenziando la presenza di informazione ridondante.




Figura 1: Matrice di correlazione nel caso di singola abitazione

Analizzando invece i risultati ottenuti dai diversi modelli, si può osservare che:

- Le regressioni lineari hanno ottenuto prestazioni molto competitive. Nel caso senza feature selection tutte e tre le tipologie utilizzate mostrano valori di NMAE compresi tra 0.088 e 0.090 e valori di NRMSE tra 0.110 e 0.113. Questo potrebbe suggerire che il problema presenta una componente prevalentemente lineare e che una parte significativa della variabilità del nostro target possa essere spiegata direttamente dalle feature.

MODEL	FS	NMAE	NRMSE
Linear Regression	NO FS	0.088218	0.110103
Linear Regression	KBEST	0.176171	0.219632
Linear Regression	LASSO	0.0934872	0.116205
Linear Regression	RF	0.1499	0.18564

Tabella 1: Risultati finali per Linear Regression

MODEL	FS	NMAE	NRMSE
Lasso Regression	NO FS	0.0900089	0.112493
Lasso Regression	KBEST	0.17674	0.22011
Lasso Regression	LASSO	0.093293	0.115889
Lasso Regression	RF	0.152108	0.188987

Tabella 2: Risultati finali per Lasso Regression

MODEL	FS	NMAE	NRMSE
Ridge Regression	NO FS	0.090204	0.11278
Ridge Regression	KBEST	0.176323	0.219784
Ridge Regression	LASSO	0.0934337	0.116178
Ridge Regression	RF	0.152099	0.188906

Tabella 3: Risultati finali per Ridge Regression

- Gli algoritmi ensemble hanno invece mostrato prestazioni inferiori. Random Forest ha ottenuto il miglior risultato con la feature selection tramite Random Forest (NMAE = 0.108 e NRMSE = 0.144) mentre AdaBoost risulta essere il modello meno efficace con valori di NMAE superiori a 0.12 in tutte le configurazioni.

MODEL	FS	NMAE	NRMSE
Random Forest	NO FS	0.1114	0.146165
Random Forest	KBEST	0.162033	0.204594
Random Forest	LASSO	0.114433	0.147359
Random Forest	RF	0.108356	0.143881

Tabella 4: Risultati finali per Random Forest

MODEL	FS	NMAE	NRMSE
AdaBoost	NO FS	0.123491	0.1553
AdaBoost	KBEST	0.184829	0.228206

MODEL	FS	NMAE	NRMSE
AdaBoost	NO FS	0.123491	0.1553
AdaBoost	LASSO	0.121382	0.151047
AdaBoost	RF	0.132159	0.165532

Tabella 5: Risultati finali per AdaBoost

- Mentre la migliore configurazione complessiva è ottenuta dalla SVR senza applicare feature selection, con un valore di NMAE pari a 0.085 ed NRMSE pari a 0.107. Tali valori evidenziano la capacità del modello di descrivere con buona accuratezza l'andamento della *Cooling Demand*.

MODEL	FS	NMAE	NRMSE
SVR	NO FS	0.0849697	0.107439
SVR	KBEST	0.178521	0.233628
SVR	LASSO	0.0865671	0.108773
SVR	RF	0.0945518	0.123293

Tabella 6: Risultati finali per SVR

La Figura 2 mostra invece il confronto tra i valori reali e predetti della soluzione migliore, corrispondente alla SVR senza feature selection. Si osserva come la maggior parte delle osservazioni risulti distribuita in prossimità della diagonale ideale, evidenziando quindi una buona corrispondenza tra valori reali e valori predetti.

Nel complesso, i risultati evidenziano come l'utilizzo dell'intero insieme di feature rappresenti la scelta più efficace per questo problema di forecasting e la superiorità da parte della SVR suggerisce la presenza di relazioni non completamente lineari che il modello riesce a catturare in maniera più efficace rispetto agli altri modelli. Infatti rispetto al secondo miglior modello (Linear regression senza feature selection), la SVR ha

ottenuto una riduzione della NMAE di circa il 3,7% e una riduzione della NRMSE di circa il 2,4%, confermando quindi il vantaggio offerto dall'utilizzo di un modello in grado di rappresentare relazioni non lineari.




Figura 2: Confronto tra variabili reali e variabili predette del risultato migliore

5.4 Risultati vicinato

La presente sezione invece riporta i risultati ottenuti nel secondo scenario analizzato, relativo alla previsione della *Carbon Intensity* a livello di vicinato. A differenza del caso precedente, il dataset è stato costruito integrando le informazioni relative a più abitazioni (Building_1, Building_2, Building_3) insieme alle stesse variabili ambientali. L'obiettivo è di prevedere l'andamento della *Carbon intensity*, una variabile caratterizzata da una maggiore complessità poiché influenzata da molteplici fattori energetici e ambientali.

L'analisi preliminare della matrice di correlazione (Figura 3) evidenzia come in questo caso ci sia una struttura più complessa rispetto al caso precedente. Sono infatti presenti numerose correlazioni tra variabili energetiche e climatiche, oltre a forti dipendenze tra le variabili meteorologiche e le rispettive previsioni. Questa elevata dimensionalità, unita alla presenza di feature fortemente correlate tra loro, suggerisce una significativa ridondanza informativa e rende particolarmente interessante valutare l'effetto delle tecniche di Feature Selection.




Figura 3: matrice di correlazione nel caso di vicino

L'analisi dei risultati mostra un comportamento sensibilmente differente rispetto allo scenario precedente. Infatti possiamo osservare che:

- le regressioni lineari e la SVR non rappresentano più le soluzioni migliori. Infatti nelle configurazioni prive di feature selection, vediamo come in questo caso tutti e quattro i modelli producano valori di NMAE compresi tra 0.26 e 0.28, evidenziando un peggioramento delle prestazioni rispetto al caso precedente. Questo risultato suggerisce che la previsione sia caratterizzata da relazioni più complesse e da dinamiche non lineari.
- Un aspetto particolare riguarda l'effetto della tecnica di SelectKBest. A differenza di quanto osservato nel problema precedente, produce un miglioramento consistente. Ad esempio, la Linear Regression registra una riduzione della NMAE da 0.277 a 0.231, mentre la Ridge passa da 0.270 a 0.231. Anche la SVR migliora passando da 0.261 a 0.233.
- Questi miglioramenti suggeriscono che il dataset preso in esame contenga una quantità maggiore di variabili ridondanti o irrilevanti. L'utilizzo della Feature Selection consente quindi ai modelli di concentrarsi sulle feature maggiormente correlate alla variabile target, migliorando di conseguenza la capacità di generalizzazione

MODEL	FS	NMAE	NRMSE
Linear Regression	NO FS	0.27744	0.336407
Linear Regression	KBEST	0.231278	0.289552
Linear Regression	LASSO	0.264453	0.31315
Linear Regression	RF	0.263981	0.32118

Tabella 7: Risultati finali per Linear Regression

MODEL	FS	NMAE	NRMSE
Lasso Regression	NO FS	0.261111	0.321834
Lasso Regression	KBEST	0.230376	0.288054
Lasso Regression	LASSO	0.261696	0.309216
Lasso Regression	RF	0.260521	0.317211

Tabella 8: Risultati finali per Lasso Regression

MODEL	FS	NMAE	NRMSE
Ridge Regression	NO FS	0.270044	0.329053
Ridge Regression	KBEST	0.23055	0.288435
Ridge Regression	LASSO	0.263654	0.311979
Ridge Regression	RF	0.261753	0.318637

Tabella 9: Risultati finali per Ridge Regression

MODEL	FS	NMAE	NRMSE
SVR	NO FS	0.260996	0.322624
SVR	KBEST	0.233127	0.286269
SVR	LASSO	0.254679	0.30743
SVR	RF	0.272123	0.345822

Tabella 10: Risultati finali per SVR

- Gli algoritmi ensemble hanno invece ottenuto le prestazioni migliori. Infatti AdaBoost raggiunge il proprio miglior risultato nella configurazione senza la feature selection, ottenendo valori di NMAE pari a 0.224 e di NRMSE pari a 0.275. Tuttavia la Random Feature senza feature selection risulta avere le migliori prestazioni complessive che ottiene un NMAE pari a 0.218 e un NRMSE vicino a 0.274. Tale risultato evidenzia come i modelli ensemble riescano a modellare relazioni non lineare e interazioni complesse tra le variabili, caratteristiche che sembrano particolarmente rilevanti nel problema preso in considerazione.
- Notiamo inoltre come per entrambi i modelli, ottengano i migliori risultati utilizzando l'intero insieme di feature. Questo suggerisce che i metodi ensemble siano in grado di sfruttare anche informazioni secondarie o debolmente correlate al target. La rimozione di tali feature quindi potrebbe ridurre la quantità di informazione disponibile.

MODEL	FS	NMAE	NRMSE
AdaBoost	NO FS	0.224273	0.274978
AdaBoost	KBEST	0.246432	0.292228
AdaBoost	LASSO	0.237848	0.288151
AdaBoost	RF	0.242646	0.293817

Tabella 11: Risultati finali per AdaBoost

MODEL	FS	NMAE	NRMSE
Random Forest	NO FS	0.217955	0.273833
Random Forest	KBEST	0.243372	0.296301
Random Forest	LASSO	0.228439	0.287894
Random Forest	RF	0.221471	0.284037

Tabella 12: Risultati finali per Random Forest

La Figura 4 mostra il confronto tra i valori reali e quelli predetti dalla configurazione migliore, corrispondente alla Random Forest senza feature selection. Rispetto al caso della singola abitazione, è presente una dispersione maggiore, confermando la maggiore difficoltà del problema. Nonostante ciò, il modello riesce comunque a seguire adeguatamente il trend generale della serie temporale. Si osserva inoltre una leggera tendenza del modello a sovrastimare i valori reali molto bassi e, simmetricamente, a sottostimare alcuni valori reali più alti.




Figura 4: Confronto tra variabili reali e variabili predette del risultato migliore

Capitolo 6

Conclusione

6.1 Sommario dell'esperimento

L'obiettivo del presente progetto è stato valutare l'applicabilità di diversi modelli di Machine Learning al problema di forecasting, nello specifico nel contesto delle Smart Building. In particolare sono state analizzate due situazioni differenti, a livello di singola abitazione e a livello di vicinato, con due target differenti, rispettivamente la previsione della *Cooling Demand* e della *Carbon Intensity*.

L'analisi è stata condotta utilizzando i dataset forniti dalla CityLearn Challenge, sui quali è stato applicato una fase di pre-processing. Successivamente a ciò, sono stati confrontati sei modelli differenti, ciascuno valutato in quattro differenti configurazioni: senza feature selection, con SelectKBest, con Lasso e con Random Forest.

Inoltre riguardo ai modelli, la configurazione degli hyper-parametri è stata ottimizzata mediante Grid Search combinata con la TimeSeriesSplit, mentre la valutazione finale delle prestazioni è stata eseguita tramite la procedura di Time Series Cross Validation utilizzando come metriche la NMAE e la NRMSE.

Analizzando i risultati, sono state evidenziate differenze significative tra i due problemi premi in esame: nel caso della singola abitazione, la SVR senza feature selection è risultata essere la configurazione complessiva migliore, ottenendo valori di NMAE e NRMSE rispettivamente pari a 0.085 e 0.107; nel caso del vicinato invece, la migliore configurazione complessiva è risultata essere Random Forest senza feature selection, con un NMAE pari a 0.218 e NRMSE pari a 0.274. Possiamo vedere come le prestazioni siano drasticamente inferiori rispetto al caso precedente e questo è sintomo di una maggiore complessità e una maggiore presenza di relazioni più articolate tra le variabili.

Mentre riguardo alle feature selection, i risultati mostrano come l'impatto di questa tecnica dipenda fortemente dal contesto. Infatti nel primo caso, l'utilizzo dell'intero insieme di feature si è rivelato essere la scelta migliore, mentre nel caso del vicinato, la tecnica SelectKBest ha spesso portato ad un miglioramento delle prestazioni dei modelli lineari, evidenziando quindi la presenza di feature ridondanti o irrilevanti.

Complessivamente, le analisi svolte confermano che le tecniche di Machine Learning possono rappresentare strumenti efficaci per il forecasting nel campo delle Smart Building, purché venga svolta un'attenta analisi sulla scelta del modello e delle feature per il problema considerato.

6.2 Limitazioni

I risultati quindi possono essere considerati nel complessivo soddisfacenti, ma tuttavia la nostra analisi presenta alcune limitazioni che meritano di essere evidenziate.

La prima limitazione riguarda il numero di algoritmi considerati. Sebbene siano stati analizzati modelli appartenenti a differenti famiglie, non sono stati inclusi modelli frequentemente utilizzati nei problemi di forecasting, come XGBoost o Gradient Boosting Regressor, che avrebbero potuto fornire ulteriori elementi di confronto. Inoltre non sono stati considerati nemmeno modelli statistici classici per serie temporali, come ARIMA o SARIMA, i quali avrebbero potuto rappresentare un ulteriore termine di paragone rispetto agli approcci di Machine Learning.

Un'altro limite è l'aver utilizzato unicamente il dataset legato alla CityLearn Challenge. Anche se ovviamente è molto rilevante per il contesto preso in esame, l'analisi su ulteriori dataset con scenari differenti potrebbe permettere di verificare le capacità di generalizzazione dei modelli e la robustezza dei risultati ottenuti.

Inoltre, riguardo alla feature selection, quest'ultima è stata effettuata utilizzando esclusivamente tecniche relativamente semplici. Quindi si

potrebbe pensare in un lavoro futuro di impiegare anche strategie più avanzate come i metodi wrapper.

6.3 Obiettivi futuri

Quindi grazie ai risultati ottenuti e ai limiti appena citati, una prima espansione di questo studio potrebbe riguardare l'integrazione di modelli ensemble più avanzati, come il citato XGBoost, al fine di confrontare le loro prestazioni con le configurazioni migliori ottenute di entrambi gli scenari presi in esame.

Poi come indicato sempre nei limiti, si potrebbe riguardare l'esplorazione delle feature selection e quindi anche in questo caso confrontare la migliore feature selection complessiva di entrambi gli scenari e confrontare i risultati che si potrebbero ottenere con metodi più avanzati.

Un altro possibile miglioramento consiste nell'estendere la ricerca degli hyper-parametri attraverso strategie più sofisticate, come la Random Search, che consentono di esplorare spazi più ampi e in alcuni casi individuare configurazioni migliori rispetto alla Grid Search.

Infine, ovviamente, sarebbe interessante applicare la metodologia proposta a dataset differenti, sia nelle variabili sia nella dimensionalità, relativi sempre al campo delle Smart Building e confrontare le prestazioni al fine di verificare la capacità di generalizzazione dei modelli scelti e la robustezza dei risultati ottenuti con il presente progetto.

Bibliografia

- [1] D. Mariano-Hernández, L. Hernández-Callejo, F. Santos García, O. Duque-Perez e A. L. Zorita-Lamadrid, “A Review of Energy Consumption Forecasting in Smart Buildings: Methods, Input Variables, Forecasting Horizon and Metrics,” *Applied Sciences*, vol. 10, n. 23, art. 8323, 2020. DOI: 10.3390/app10238323.
- [2] M. Huotari, A. Malhi e K. Främling, “Machine Learning Applications for Smart Building Energy Utilization: A Survey,” *Archives of Computational Methods in Engineering*, vol. 31, pp. 2537–2556, 2024. DOI: 10.1007/s11831-023-10054-7.
- [3] F. El Hussein, H. N. Noura, O. Salman e K. Chahine, “Machine Learning in Smart Buildings: A Review of Methods, Challenges, and Future Trends,” *Applied Sciences*, vol. 15, art. 7682, 2025. DOI: 10.3390/app15147682.
- [4] K. Alanne and S. Sierla, “An overview of machine learning applications for smart buildings,” *Sustainable Cities and Society*, vol. 76, Art. no. 103445, 2022, doi: 10.1016/j.scs.2021.103445.
- [5] [Alcrowd, “Forecasting Track: CityLearn Challenge,” NeurIPS 2023 CityLearn Challenge.](#)